

基于跨域适应的风电传动 链智能故障诊断方法研究

摘 要

随着风力发电行业的快速发展，风力发电已在可再生能源发电领域中占据十分重要的地位。值得注意的是，风电传动链作为风电机组的关键部件，其故障不仅是引发风电机组非计划停机的关键因素，还容易造成重大经济损失。因此，对风电机组传动链的健康监测与故障诊断技术逐渐成为保障其稳定运行和提升经济效益的关键。

然而，现有数据驱动方法在应对实际工业场景中普遍存在的数据分布差异问题时面临显著挑战，特别是在新工况或小概率工况下可获取的有效状态数据极为有限，严重制约了智能诊断模型的性能表现。

针对该问题，本文深入开展了基于跨域适应的风电传动链故障诊断研究。首先，使用格拉姆角和场算法将设备的时序状态数据编码为二维图像表征，并基于WGAN(Wasserstein GAN)方法生成高保真虚拟样本，有效缓解数据稀缺工况的样本不足问题。在此基础上，本文提出了基于卷积神经网络和迁移学习技术的两阶段跨域故障诊断的方法，通过对齐不同工况数据的分布，实现从多数据工况向少数据工况的诊断知识迁移。实验结果证明，本文所提方法能够有效实现故障特征提取与跨域知识迁移，在跨域诊断任务中具有较好的诊断性能。

关键词：故障诊断；迁移学习；卷积神经网络；生成对抗网络；风电机组

ABSTRACT

With the rapid development of the wind power industry, wind energy has become a highly significant component of renewable energy generation. The drivetrain, as a critical component of wind turbines, plays a pivotal role; its failure is a leading cause of unplanned shutdowns and can result in substantial economic losses. As such, health monitoring and fault diagnosis of wind turbine drivetrains have become essential for ensuring operational stability and improving economic efficiency.

However, existing data-driven approaches face major challenges in real-world industrial scenarios, particularly due to discrepancies in data distributions. These challenges are further exacerbated under new or rare operating conditions, where available data are extremely limited, and this significantly restricts the performance and generalization capabilities of intelligent diagnostic models.

To address this issue, this study investigates a cross-domain adaptation-based fault diagnosis approach for wind turbine drivetrains. Specifically, the Gramian Angular Summation Field method is used to convert sequential condition data into two-dimensional image representations. Subsequently, a Wasserstein GAN (WGAN) is employed to generate high-fidelity samples, effectively mitigating the issue of data scarcity in rare operating conditions. On this basis, a two-step cross-domain fault diagnosis method is proposed, integrating convolutional neural networks with transfer learning techniques. By aligning the data distributions under varying operating conditions, this method enables the transfer of diagnostic knowledge from data-rich to data-scarce domains. Experimental results demonstrate that the proposed approach achieves effective fault feature extraction and robust knowledge transfer, delivering strong diagnostic performance in cross-domain scenarios.

Key words: fault diagnosis; transfer learning; CNN; GAN; wind turbine

目 录

第一章 绪论	1
1.1 研究背景与意义	1
1.2 研究现状	1
1.2.1 传统故障诊断方法	2
1.2.2 基于深度学习的故障诊断方法	2
1.2.3 基于领域自适应技术的故障诊断方法	3
1.3 研究内容	4
1.4 论文组织结构	4
第三章 基于 WGAN 的数据集扩充方法	6
3.1 引言	6
3.2 数据预处理	6
3.2.1 原始数据集介绍	6
3.2.2 数据格式转换	7
3.2.3 截取样本	8
3.2.4 时间序列图像化	8
3.2.5 数据集制作	10
3.3 基于 WGAN 的目标域数据扩充	12
3.3.1 网络架构	12
3.3.2 损失函数和优化器	13
3.3.3 虚拟样本生成与数据集扩充	14
3.4 本章小结	16
第四章 基于 CNN 和迁移学习的两阶段跨域诊断方法	17
4.1 引言	17
4.2 TS-CDFD 方法说明	17
4.2.1 方法流程说明	17
4.2.2 方法中网络结构说明	19
4.2.3 各阶段中训练参数设置及损失值的计算方法	20
4.3 实验设计	20
4.3.1 跨域诊断任务介绍	21
4.3.2 实验步骤设置	21
4.4 结果分析	22
4.4.1 源域训练结果分析	22
4.4.2 跨域故障诊断任务结果分析	24

4.4.3 对比实验结果分析	29
4.5 本章小结	29
第五章 总结与展望	31
5.1 研究总结	31
5.2 研究展望	31
结束语	32
参考文献	33

第一章 绪论

1.1 研究背景与意义

风力发电作为可再生能源的重要组成部分，至 2023 年底为止，其全球发电装机容量已经高达 10.15 亿 kW；同期，可再生能源总装机容量也已增至 42.46 亿 kW，在全球总发电装机容量中占比较高^[1]。这说明风力发电技术，在可再生能源发电中占有十分重要的地位。在风电机组中传动链是实现能量转换的关键部件，该部件的运行状态会直接影响风电机组的能量转换效率、安全性和经济效益。大部分风力发电机部署在海上或者较为偏远的陆地，由于环境恶劣，机组易发生机械故障。这些故障往往会导致风电机组非计划停机，其中传动链故障的影响尤其显著，由其导致的非计划停机时间占比超过 87%^[2]。而且，对传动链故障的维修费用也十分高昂，在总维修费用中占比超过 75%^[2]。因此，使用高效的故障诊断方法实现风电传动链的健康状态监测尤为必要，这不仅能够及时识别潜在的故障、避免灾难性事故的发生、保障机组的安全运行，还可以提升风电场的经济效益。

得益于传感器技术在风电机组中的运用，将其与数据处理技术相结合以构建的设备健康状态检测系统，可以实时获得风电机组的工况信息和设备状态信息，这使得基于数据驱动的故障诊断方法能够得以实现^[3]。然而，通过设备健康状态检测系统获得的数据中数据量最大的是风电机组在常见工况（源域）下工作时的设备状态信息，而出现概率较小的工况或新工况（目标域）下的设备状态信息往往数据量较少。这种数据的缺少使得在小概率工况或新工况下对风电机组传动链进行故障诊断遇到了挑战。因为这些工况下设备状态信息较少，会使得如深度学习等基于数据驱动的故障诊断方法在这些工况下难以充分发挥作用。因此，对于如何在小概率工况或新工况下仅利用较少的设备状态信息，即可使基于数据驱动的方法实现较为准确的故障诊断，有着重要的研究意义。

此外，由于风电机组常会遇到方向和负荷均不固定的风力冲击，导致其所处的工况十分多变，因此如果针对风电机组可能会处于的每类工况，都单独利用该工况下设备状态信息从无到有地实现一种可用于该工况下故障诊断的方法，虽然在技术层面可行，但是该方案的复杂性较大且成本较高，因此该方案缺少实际应用价值。所以，实现可以跨域适应的故障诊断方法，在实际工业场景中更具有应用价值。对该类方法的简单理解是，利用常见工况下数据量充足的设备状态信息辅助数据驱动的故障诊断方法在设备状态信息较少的工况下实现有效的故障诊断。

1.2 研究现状

本文所研究的跨域故障诊断方法，针对的目标是风电机组的传动链。风电机组传动链的关键机械部件是滚动轴承和齿轮，由于风电机组的工作环境较为恶劣且机械部件自身也会因为长时间工作而性能退化，所以这些机械部件易于发生故障，而且故障一旦发生，将会显著影响风电场的经济效益甚至可能导致生产安全事故。

因此,本研究方法的应用任务是针对风电传动链的这些机械部件进行故障诊断。滚动轴承的故障通常会由于磨损、点蚀、形变而出现在内圈、外圈和滚动体部位。齿轮的常见故障则包括齿轮缺齿、齿根发生断裂、齿轮损坏。

对于上述机械故障,已经有研究者提出了多种故障诊断方法。为了更好地说明当前故障诊断方法的研究现状,本文将从传统故障诊断方法、基于深度学习的故障诊断方法以及基于领域自适应技术的故障诊断方法这三个方面,对已有的相关研究进行简要的概述。

1.2.1 传统故障诊断方法

传统故障诊断方法对故障特征的识别,依赖于人工设计的信号处理手段。传统方法中常用的有效技术有小波变换^[4]、频域多点峭度^[5]等,这些传统方法通过对设备运行状态下采集到的信号进行处理,从而得到信号中可用于判断设备健康状态的时域或频域特征。

与以深度学习技术为代表的驱动的数据驱动的故障诊断方法相比,传统故障诊断方法所使用的,以信号处理技术为基础的、人工设计的特征感知过程,依赖于专家的经验与先验知识,因此这些方法的自适应特征提取能力偏弱^[6],在特征选择上具有较强的主观性,难以全面捕捉复杂工况下的故障模式,在多工况时缺乏良好的通用性与可迁移性。所以这些方法在实际工业场景中难以有效运用于风电机组传动链的故障诊断。

1.2.2 基于深度学习的故障诊断方法

深度学习技术因为其优秀的自适应特征提取能力,目前已经被广泛运用于故障诊断领域,卷积神经网络是深度学习技术中一个具有代表性的模型。1998年,在文献^[7]中作者提出了卷积神经网络(Convolutional Neural Network, CNN)。作者在将这一较为原始的卷积神经网络用于完成对手写字符数据集的分类任务时,得到了较好的分类准确率。2006年,在文献^[8]中,作者通过增加卷积神经网络的层次,并提出逐层训练卷积神经网络的算法,使得作者提出的网络能够具有更多隐藏层,并且具备更加强大的特征学习能力。此后,该技术获得了极大的关注,不仅有大量学者对卷积神经网络进行研究,谷歌、微软等众多科技公司也在21世纪初就大力投入对卷积神经网络的研究和商用^[9]。

在经过近30年的发展后,卷积神经网络已经从仅有几层的神经网络,发展得层次更深、结构愈发复杂精细。目前,由于这一类型的神经网络可以对目标数据的特征进行高效的感知,所以其在图像分类^[10]、目标检测^[11]等领域发挥着巨大的作用。

故障诊断领域的核心任务通常是对采集到的大量设备状态信息进行故障分类,而这正是卷积神经网络擅长的应用场景。因此,该技术已被广泛用于故障诊断领域。在文献^[12]作者提出的故障诊断方法中,卷积神经网络技术结合使用支持向量机技术,有效增加了对变压器故障诊断的准确度和鲁棒性。在文献^[13]中,作者将

小波包分解与卷积神经网络相结合，成功实现了对风电机组齿轮传动机械的故障诊断。

在上述文献中，研究者们均是通过将卷积神经网络与其他机器学习技术或信号处理技术相结合，以成功实现在大规模、有标签的工况信息数据集上进行有效的故障诊断。这证明了卷积神经网络特征提取能力的高效性和对分类任务的适应性，让其可以被有效地运用于故障诊断领域。但是，以卷积神经网络为代表的深度学习技术的有效性，依赖于使用大量的有标签数据对其进行训练。这也就意味着，在故障诊断领域如果要使用该技术，需要提前获得足够多的设备状态信息，并且要对这些信息进行标注。尽管使用监测系统可以高效地采集设备状态信息，并依据工况和设备状态对信息进行标注。可是，如果要获得足够多设备故障时的状态信息，就必须令设备在故障状态下运行足够长时间，这在实际工业场景下是难以实现的。因此，在一个设备状态信息较少的工况中，仅使用卷积神经网络或其他传统的深度学习技术，难以对该工况中的设备健康状态进行准确的诊断。

1.2.3 基于领域自适应技术的故障诊断方法

在实际的工业场景中，获取大量小概率工况或新工况下的设备状态信息往往需要设备在故障状态下长时间运行，这在现实中难以实现。迁移学习技术可以为解决这一难题提供有效的方案。在对计算机图形学的研究中，研究者成功使用迁移学习技术实现了依靠大量有标签的源域数据集，对仅有少量数据的目标域数据集完成图像分类或风格迁移等任务。在文献^[14]中，作者将卷积神经网络 EfficientNetV2 与参数迁移技术相结合，减少了卷积神经网络参数因为随机初始化而导致的梯度消失问题并且减少了卷积神经网络在训练时会陷入局部最优解的风险，从而实现目标域数据集进行有效的图像分类。在文献^[15]中，作者将迁移学习技术与生成对抗网络相结合，从而提出了循环一致性生成对抗网络，在源域和目标域中图像样本数不同、两个域之间的样本无法完全配对的情况下，该网络仍然可以学习使用者需要得到的风格，并实现以原有风格的图像为输入后，最终生成符合希望得到的风格的图像。

适合使用迁移学习技术的研究方向是：在多个域上，虽然各个域样本的特征分布不同，但在各个域上执行的任务相同。这与实际工业场景中，需要利用设备状态信息充足的工况下的数据，辅助模型更好地在目标工况下进行故障诊断训练的需求相适应。实际工业场景下，存在大量源域设备状态信息和少量目标域的设备状态信息，使用迁移学习技术、充分且合理地利用源域工况数据对模型进行辅助训练，使得故障诊断模型在目标工况下可以诊断设备健康状态，这一任务被称为跨域故障诊断^[16]。

领域自适应技术是迁移学习技术中一个已经被泛用的子技术。常用领域自适应技术的类型包括基于分布差异、基于对抗学习和基于重构，如今研究者已经将这三类技术都成功运用于工业界的故障诊断^[17]。在这些领域自适应技术中，基于分

布差异的技术通常会使用最大均值差异（Maximum Mean Discrepancy, MMD）^[18]等统计矩匹配算法来衡量源域数据和目标域数据的差异，并将这种差异作为模型训练时损失值的一部分。在文献^[19]中，作者将基于 MMD 算法改进而来的 CMD 算法与卷积神经网络相结合，实现了域适应卷积神经网络，并成功将该网络用于对轴承故障的诊断。基于对抗学习的领域自适应技术是依据生成对抗网络的理论基础而产生的。由于在实现方式上的差异，该技术可以进一步根据是生成式还是非生成式而分为两类子方法。由于这两类子方法均具有强大的灵活性和鲁棒性，现在已经被广泛用于故障诊断的研究中^[17]。在文献^[20]中，作者将 MMD 算法与生成式对抗领域自适应方法结合，实现了较准确地诊断轴承设备的故障。在文献^[21]中，作者使用的对抗领域自适应方法，是非生成式的、基于 Wasserstein 距离的，作者使用该方法实现了对少标签或无标签数据的故障诊断。故障诊断时如果使用了基于重构的领域自适应技术，则往往会将其与生成对抗网络相结合^[17]。例如，在文献^[22]中，作者将生成对抗网络和堆叠去噪自编码器结合，成功实现了生成与原始信号具有相似分布的新信号，并将新信号与原始信号共同用于故障诊断。

1.3 研究内容

本研究模拟的实际工业场景是在新工况或小概率工况（目标域）下设备状态信息较少而旧工况或常见工况（源域）下设备状态信息充足的情况。研究的目的是实现使用源域中充足的设备状态信息和目标域下较少的设备状态信息、结合迁移学习方法训练出可以有效用于源域和目标域故障诊断的跨域诊断模型。因此本研究的主要内容如下：

首先，对所选择的原始数据集中时间序列类型的数据进行预处理，使用滑动窗口法对数据进行截取从而获得各工况各状态下时间序列类型的振动信号样本，再使用格拉姆角和场算法与伪彩色增强技术将这些时间序列样本编码为彩色图像样本，之后，本研究根据这些彩色图像来自的工况和状态的不同，将它们制作成代表旧工况或常见工况的源域数据集和代表新工况或小概率工况的目标域数据集。

为了缓解目标域数据集中样本较少的问题，本研究使用了对抗性生成技术以实现增加该域下的数据，分别在各个目标域数据集的真实样本上训练生成器以使其学习目标域真实样本的特征，充分训练后的生成器生成的虚拟样本在真实度上会逼近真实样本，在目标域数据集中增加这些虚拟样本后，其样本总数会更满足数据驱动的故障诊断方法的需要。

在增加目标域数据后，本研究为了实现可以运用于跨域故障诊断任务的方法，将卷积神经网络与域适应和微调技术结合使用，形成一个两阶段跨域故障诊断方法。在相关数据集上分别完成各个跨域诊断任务，对该方法进行验证，并对其诊断性能进行了系统性的分析与评估。

1.4 论文组织结构

第一章简要概述了本研究的对象。对实现适用于风电传动链的跨域适应的智

能故障诊断方法的研究背景以及应用意义，进行了简要说明。同时，简要回顾了相关领域已有研究成果，并概述了本研究的目标与所采用的技术路线。

第二章对研究中采用的关键方法与技术进行了说明，包括对抗性生成原理的应用、卷积神经网络中的相关组件、最大均值差异算法以及故障诊断模型的评价指标。

第三章是说明基于 WGAN 的数据集扩充方法。这一章介绍了本研究选取原始数据集并对其中数据进行相关处理以获得研究用数据集的过程。对本研究使用的基于 WGAN 算法搭建的生成对抗网络进行相关介绍，并阐述用其扩充目标域数据集的过程。

第四章说明的是基于 CNN 和迁移学习的两阶段跨域诊断方法。这一章介绍了本研究搭建的卷积神经网络的相关信息，以及将其与微调技术和域适应技术相结合而形成的两阶段跨域诊断方法。并在最后分析了该方法的效果。

第五章是本文对所做的关于跨域故障诊断方法研究的总结与展望。这一章总结了本研究为实现跨域故障诊断所做的工作和最终结果，并提出了未来应该在无监督方向和在线学习方向进一步探索。

第三章 基于 WGAN 的数据集扩充方法

3.1 引言

对于实际工业场景中小概率工况或新工况（目标域）下设备状态数据较少的问题，本研究模拟了这一场景，并针对该问题使用了相关方法进行研究。

本研究采用了合适的数据增强方法来增加目标域样本数，从而缓解目标工况下设备状态数据不足的问题。数据增强方法中，较为经典的方法包括基于位移与变形的方 法、依据图像 RGB 三通道信息进行处理的方法，以及基于插值策略的方法和类别混合增强方法等^[27]。尽管这些方法能简单高效地增加样本数量，但是由于增加规则是由使用者定义的，所以往往难以灵活适配于任务的需要^[27]。如前文所述，生成对抗网络具有强大的学习能力和普遍适用性，目前已受到大量研究者的关注并被广泛用于虚拟数据生成任务中^[27]。

由于生成对抗网络相较于传统数据增强方法更具泛用性，所以在故障诊断领域，使用生成对抗网络生成虚拟样本，已经成为一种普遍使用的方法。在文献^[28]中，作者使用音频波形生成对抗网络实现了对变压器机械故障声纹样本数据集的扩充。在文献^[29]中，作者则是使用生成对抗网络对舰炮故障样本进行了增强处理。

因为生成对抗网络更善于学习和生成图像数据^[30]，所以，在本研究中也搭建了用于生成图像的生成对抗网络，并且选择了合适的算法将非图像类型的设备状态信息编码为图像。

本章的主要工作内容如下：

选择适合于本研究的原始数据集，采用一系列方法将原始数据集中的时间序列数据编码为图像，并制作用于生成对抗网络训练的模拟工况数据集。

搭建基于 WGAN 的生成对抗网络，并在模拟数据集中目标域数据集上进行训练，以生成较真实的虚拟样本，再用虚拟样本扩充模拟工况数据集，从而制作用于跨域故障诊断的数据集。

3.2 数据预处理

3.2.1 原始数据集介绍

为验证本文所提方法的有效性，分别采用滚动轴承和行星齿轮箱数据集构建诊断任务。

（1）凯斯西储大学（Case Western Reserve University, CWRU）轴承故障数据集^[31]，数据集来源的试验平台如图 3.1 所示。CWRU 提供的数据包含多个工作负荷下，使用正常或不同故障类型的轴承工作时设备的振动信号数据。这些数据可以开发和验证用于故障诊断的各类模型。

在 CWRU 数据集中，本研究选取了按 48KHz 采样频率采样得到的振动信号数据，根据这些数据对应的采样场景中设备工作的负荷不同而将数据分类为 4 种

不同的工况，这 4 种工况的负荷分别为 0HP、1HP、2HP、3HP，本文中会使用负荷来代表各个数据或数据集所属的不同工况。根据每种工况中轴承状态的不同，又可以将设备状态分为无故障状态和故障状态，故障状态中包含不同的故障位置，包括转动体故障、内圈故障和外圈故障。

(2) 北京工业大学和北京交通大学公开的 WT-行星齿轮箱数据集^[32]，本文将该数据集简称为行星齿轮箱数据集。数据集来源的试验平台如图 3.2 所示。与上述轴承故障数据集相比，此数据集的采样时间更长、传感器安装位置更多、设备状态更多，因此非常适用于有关智能故障诊断中，模型泛化能力与迁移学习方法的相关研究^[33]。

在北京工业大学和北京交通大学公开的 WT-行星齿轮箱数据集中，本研究选择了转速分别为 20Hz、25Hz、30Hz、35Hz 四种工况下于设备 X 轴采集到的振动信号数据，本文中以转速来代表各个数据或数据集所属的不同工况。并且，本研究在该数据集的上述工况数据中选取健康、缺齿、齿根断裂、齿轮损坏这 4 种设备状态的数据。




图 3.1 CWRU 数据集采样试验台



图 3.2 行星齿轮箱数据集采样试验台

3.2.2 数据格式转换

本研究使用的两类数据集的原始数据均存储在.mat 格式的文件中，这是一种专为 MATLAB 环境设计的格式，通常用于保存多维数组、矩阵、变量和实验结果。然而，由于本研究使用的 TensorFlow、PyTorch 等深度学习框架主要支持如.csv、.npy、.h5 等通用数据格式，如果直接使用.mat 文件则无法进行数据处理和

模型训练，需要进行数据格式转换。

因此，本研究先对原始数据进行格式转换。从每个数据文件中提取出需要的时间序列数据并确保数据的维度一致，将源于同一工况下不同设备状态的时间序列数据保存在同一个.csv 文件中。并将文件导出以便于后续对数据的进一步处理。

3.2.3 截取样本

滑动窗口法（Sliding Window）是一种在处理时间序列数据时常用的技术，用于从数据中截取样本。滑动窗口法的过程如下：假设有一个振动信号的时间序列为 $[x_1, x_2, x_3, \dots, x_n]$ ，若窗口大小为 5、步长为 1，则截取到的第一个样本 $S_1 = [x_1, x_2, x_3, x_4, x_5]$ 、第二个样本 $S_2 = [x_2, x_3, x_4, x_5, x_6]$ 、第三个样本 $S_3 = [x_3, x_4, x_5, x_6, x_7]$ ……以此类推。

数据集中设备的振动信号数据包含周期性和瞬时性变化，尤其是在发生故障时，信号往往表现出明显的局部波动或突发性变化。使用滑动窗口法对原始时序信号进行截取，通过不断滑动窗口，按小段逐步提取时间序列中的局部信息，有助于揭示信号中这些细微的特征^[34]。

在使用滑动窗口法时，其中窗口大小的设置取决于时间序列的性质，以及后续处理的需求，因为本研究中使用的数据集中的数据是用于故障诊断的机械振动信号，所以窗口大小应该足够大，以捕捉到设备状态信息的关键特征。因此，本研究对 CWRU 数据集中的原始数据以 896 的窗口大小和 128 的步长进行截取、对行星齿轮箱数据集中的原始数据以 7168 的窗口大小和 128 的步长进行截取。

3.2.4 时间序列图像化

在上一小节中，使用固定步长和窗口大小的滑动窗口法对原始数据中的时间序列进行截取，截取后获得的样本仍然是序列类型数据。由于序列类型数据在数据结构上是一维数组，而卷积神经网络模型以及生成对抗网络模型大多更善于处理图像数据。所以在这种情况下，为了将序列类型数据表示为图像形式，本研究使用格拉姆角和场算法（Gramian Angular Summation Field, GASF）对前文获得的序列类型数据样本进行编码。

该算法由 Wang Z 等人在文献^[35]中提出，作者为了实现对时间序列类型的数据进行分类和缺失值填充，而提出了使用计算机视觉领域的方法实现一种新的框架，在作者提出的这种框架中需要将不同类型的时间序列数据编码为不同类型的图像，然后再使用深度学习技术完成对编码后获得的不同类型的图像数据进行分类等操作，为了实现将时间序列类型的数据编码为图像数据，作者提出了格拉姆角和场算法。在本研究中使用该算法对上述序列类型数据样本进行编码处理。

格拉姆角和场算法的核心，是首先将时间序列样本通过极坐标变换的方法映射至角度空间，然后利用角度信息构造格拉姆矩阵形式的表示，这种表示结果在数据结构上是一个长宽相等的二维数组，对这个二维数组使用计算机视觉领域的方

法可以将其转化成一个单通道长宽相等的灰度图像。

因为前文中获得的序列类型数据样本较长，直接使用格拉姆角和场算法将其编码后得到的图像会过大，不利于后续生成对抗网络和卷积神经网络的计算。所以本研究在使用格拉姆角和场算法之前，先对序列类型数据样本进行分段聚合近似这一预处理。分段聚合近似是一种可以用于缩短时间序列长度的方法，它将时间序列划分为多个组，并用每组的均值代替整个组，可以在减少数据维度的同时，尽量保留数据的全局趋势信息。本研究中使用分段聚合近似的过程可以用如下公式表示：

$$w = \frac{n}{m} \quad (3-1)$$

$$\bar{x}_k = \frac{1}{w} \sum_{i=k_w}^{kw+w-1} x_i \quad (3-2)$$

公式 3-1 中 n 是单个序列类型数据样本的长度， m 是对这一序列划分的组数， w 是每组中的数值个数。公式 3-2 中 x_i 是这一样本中第 i 个数值， i 的取值范围就是每组中数值下标的取值范围。对第 k 组中的数值聚合近似处理后的结果是 \bar{x}_k ，其中下标的范围是 $k = 0, 1, 2, \dots, m-1$ 。最终，以该方法对上述任一序列类型数据样本进行处理后会得到新序列样本 $\bar{X} = [\bar{x}_0, \bar{x}_1, \dots, \bar{x}_{m-1}]$ 。在对来自 CWRU 数据集和行星齿轮箱数据集的序列类型数据样本进行分段聚合近似时设置组数为 224。

在新序列样本 $\bar{X} = [\bar{x}_0, \bar{x}_1, \dots, \bar{x}_{m-1}]$ 中，样本的数据值会过大或过小从而导致数据波动较大且这些数据均带有量纲，在使用格拉姆角和场算法时这些因素都会对编码后生成的图像数据的质量产生影响。因此，在文献^[35]中，作者提出在使用格拉姆角和场算法之前，应该先对序列类型的数据样本全都进行归一化处理，归一化处理的公式如下：

$$\tilde{x}_k = \frac{\bar{x}_k - \min(\bar{X})}{\max(\bar{X}) - \min(\bar{X})} \times 2 - 1 \quad (3-3)$$

公式 3-3 中， \bar{x}_k 是新序列样本 \bar{X} 中第 k 个数据值， $\max(\bar{X})$ 是新序列样本 \bar{X} 中最大的数据值， $\min(\bar{X})$ 是新序列样本 \bar{X} 中最小的数据值， \tilde{x}_k 是对第 k 个数据值进行归一化处理后的结果，其中 $k = 0, 1, 2, \dots, m-1$ 。最终，对新序列样本 \bar{X} 进行归一化处理后获得的最终序列样本为 $\tilde{X} = [\tilde{x}_0, \tilde{x}_1, \dots, \tilde{x}_{m-1}]$ 。

在对序列类型数据样本完成分段聚合近似和归一化处理之后获得的最终序列样本 \tilde{X} ，不仅数值波动较小，而且单个序列样本长度较短。使用格拉姆角和场算法根据该样本计算格拉姆矩阵按如下两步进行^[35]，第一步是使用公式 3-4 得到样本 \tilde{X} 中的点 \tilde{x}_k 在极坐标中的角度值：

$$\phi_k = \arccos(\tilde{x}_k) \quad (3-4)$$

公式中， \tilde{x}_k 是新序列样本 \tilde{X} 中的第 k 个值。 ϕ_k 是样本 \tilde{X} 中的点 \tilde{x}_k 在极坐标中的角度值，它的值是通过计算 \tilde{x}_k 的反余弦得到的，其中 $k = 0, 1, 2, \dots, m-1$ 。第二步是根据公式 3-5 计算格拉姆矩阵：

$$GASF(i, j) = \cos(\phi_i + \phi_j) \quad (3-5)$$

$GASF(i, j)$ 是最后获得的格拉姆矩阵，在此处也可以称之为格拉姆角和场，其中 $i, j = 0, 1, 2, \dots, m-1$ 。它的数学形式是一个形状为 $m \times m$ 的方阵， m 是在对序列类型数据样本进行分段聚合近似时设定的组数，在本研究中组数的值是 224。

使用 GASF 算法最终获得的格拉姆角和场，经过归一化处理后，可以视为一幅灰度图像。再对该灰度图像使用伪彩色图像增强技术，可以得到三通道彩色图像。

图 3.3 所示，是 CWRU 数据集中原始数据经上述处理后得到的灰度图和对应的彩色图像样本的示例。图中 0HP 代表工况，Normal、B、IR、OR 分别代表轴承的状态为正常、转动体故障、内圈故障、外圈故障。

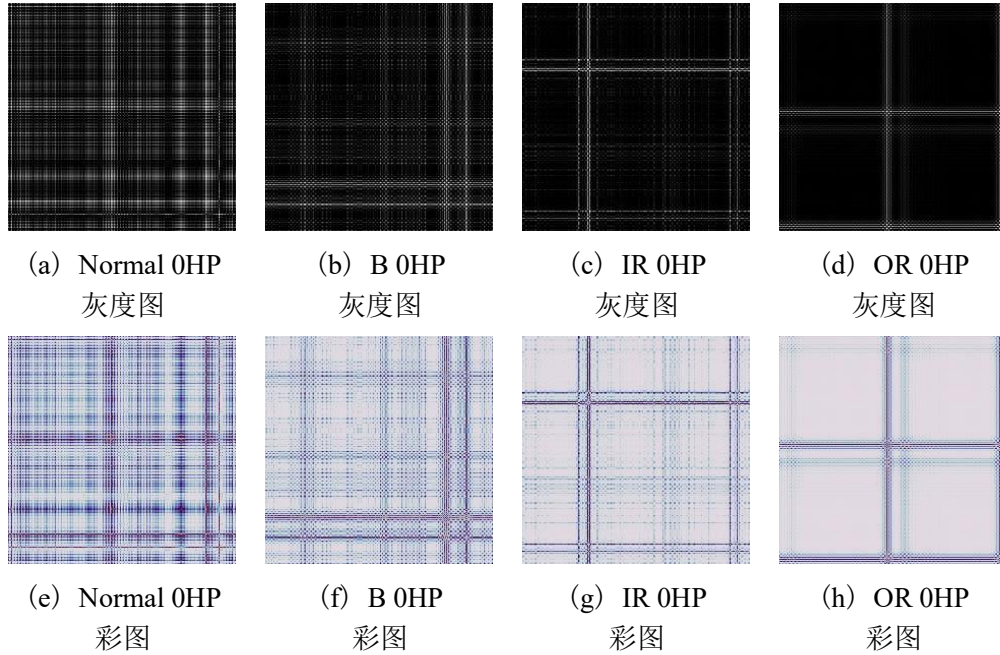


图 3.3 CWRU 数据处理后所得灰度图及其对应的彩色图像样本示例图

3.2.5 数据集制作

在上文中，已经实现了使用滑动窗口法对原始数据进行截取从而得到序列类型的数据样本，再利用格拉姆角和场算法对样本进行编码，并使用伪彩色增强技术，从而得到与各个序列类型的数据样本对应的彩色图像样本。在将这些彩色图像样本用于生成对抗网络和卷积神经网络的训练之前，需要先将这些样本制作成为合适的数据集。

本文中将从 CWRU 数据集里所选取的原始数据经上述处理而获得的全部彩色图像样本制作的数据集称为 CWRU 完整数据集，该数据集的结构如表 3.1 所示，

表中的数值代表各工况各设备状态下对应的真实样本个数。

表 3.1 CWRU 完整数据集结构表

工况	设备状态			
	正常	转动体故障	内圈故障	外圈故障
0HP	1800	1800	1800	1800
1HP	1800	1800	1800	1800
2HP	1800	1800	1800	1800
3HP	1800	1800	1800	1800

本文将从行星齿轮箱数据集中选取的原始数据经上述处理后得到的全部彩色图像样本制作的数据集称为行星齿轮箱完整数据集。行星齿轮箱完整数据集的结构如表 3.2 所示，表中的数值仍代表各工况各设备状态下对应的真实样本个数。

表 3.2 行星齿轮箱完整数据集结构表

工况	设备状态			
	健康	缺齿	齿根断裂	齿轮损坏
20Hz	2400	2400	2400	2400
25Hz	2400	2400	2400	2400
30Hz	2400	2400	2400	2400
35Hz	2400	2400	2400	2400

因为本研究模拟的工业场景中目标域的设备状态信息是少于源域的，所以上述的完整数据集可以作为各个源域数据集。但是，当由某一工况中设备状态信息制作的数据集被选择作为源域数据集时，由其余工况中设备状态信息制作的数据集则应该作为目标域数据集。因此，需要根据上述的完整数据集制作目标域数据集。本研究将目标域数据集中源自各类设备状态的样本均删减一定数量，以满足模拟工业场景中目标域数据少于源域数据的限制条件。本文将删减后获得的目标域数据集与完整的源域数据集合并后得到的数据集称为模拟数据集。CWRU 模拟数据集结构和行星齿轮箱模拟数据集结构分别如表 3.3 和表 3.4 所示。表中的数值是代表以某一工况为源域时，各域中所有设备状态下真实样本的总数。例如，表 3.3 的第一行所模拟的情况是：以 0HP 工况为源域时是则 1HP、2HP、3HP 工况为目标域，此时各域中所有真实样本的个数分别是 7200、4000、4000、4000，模拟数据集任一域中来自各设备状态的真实样本数量相同。

表 3.3 CWRU 模拟数据集结构表

源域	所有域			
	0HP	1HP	2HP	3HP
0HP	7200	4000	4000	4000
1HP	4000	7200	4000	4000
2HP	4000	4000	7200	4000
3HP	4000	4000	4000	7200

表 3.4 行星齿轮箱模拟数据集结构表

源域	所有域			
	20Hz	25Hz	30Hz	35Hz
20Hz	9600	5600	5600	5600
25Hz	5600	9600	5600	5600
30Hz	5600	5600	9600	5600
35Hz	5600	5600	5600	9600

3.3 基于 WGAN 的目标域数据扩充

3.3.1 网络架构

在本研究中，生成对抗网络需要学习的样本是由时间序列数据经过格拉姆角和场算法编码为灰度图后再用伪彩色技术增强得到的彩色图像样本。这些样本较简单，不具备与现实世界自然图像中类似的复杂纹理和结构信息。此外，在本研究中，生成对抗网络需要学习所有目标域数据集中来自不同工况与不同设备状态的彩色图像样本，进而生成用于扩充目标域数据集的虚拟样本，使其样本数量与源域数据集保持一致，这些虚拟样本是对目标域数据集中数量不足的真实样本的补充。

根据上述目标，本文基于 WGAN 算法^[36]所搭建的网络中主要的两部分的结构，分别如表 3.5 和表 3.6 所示。

表 3.5 判别器结构

层编号	层类型	输入特征数	输出特征数
1	Linear(150528,512)	150528	512
2	LeakyReLU(0.2)	-	-
3	Linear(512, 256)	512	256
4	LeakyReLU(0.2)	-	-
5	Linear(256, 1)	256	1

表 3.6 生成器结构

层编号	层类型	输入特征数	输出特征数
1	Linear(100, 128)	100	128
2	LeakyReLU(0.2)	-	-
3	Linear(128, 256)	128	256
4	BatchNorm1d(256, 0.8)	-	-
5	LeakyReLU(0.2)	-	-
6	Linear(256, 512)	256	512
7	BatchNorm1d(512, 0.8)	-	-
8	LeakyReLU(0.2)	-	-
9	Linear(512, 1024)	512	1024
10	BatchNorm1d(1024, 0.8)	-	-
11	LeakyReLU(0.2)	-	-
12	Linear(1024, 150528)	1024	150528
13	Tanh()	-	-
14	Reshape(150528, (3, 224, 224))	-	-

需要说明的是，在生成器结构中第 15 层的 Reshape(150528, (3, 224, 224))并非神经网络结构中常用的组件之一。使用该层的原因是，将随机噪声输入生成器后经过第 1 至 14 层计算最终生成的是形状为 (batch_size, 150528) 的数据，即多个向量，而并非生成形状为 (3, 224, 224)、可直接转化为三通道彩色图像的三维数组，因此需要在第 14 层之后添加 Reshape(150528, (3, 224, 224))层，将向量转化成可以存储为三通道彩色图像的三维数组。此外，在本研究中判别器的最后不添加 Sigmoid 之类的激活层，原因在 3.3.2 节中详细说明。

3.3.2 损失函数和优化器

在文献^[36]中，作者提出 WGAN 算法是为了缓解梯度消失和训练不稳定等问题，作者使用了 Wasserstein 距离来代替原来的 JS 散度和 KL 散度。因此，WGAN 算法的优化目标以及训练过程与普通生成对抗网络不完全相同，而是如公式 3-6 所示：

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim P_r} [D(x)] - \mathbb{E}_{u \sim P_u} [D(G(u))] \quad (3-6)$$

与公式 2-8 所代表的普通生成对抗网络的优化目标相同的是，在该公式中 $G(\cdot)$ 代表生成器、 $D(\cdot)$ 代表判别器、 x 和 $G(u)$ 分别代表真实样本和虚拟样本。

不同的点在于，原始生成对抗网络的判别器 $D(\cdot)$ 向生成器反馈的信息是输入样本为真实样本的可能性，而该生成对抗网络中则是对输入样本直接进行打分并反馈给生成器，判别器经过充分训练后，输入样本越真实则获得的打分越高。由于

原始判别器的作用如上所述，而概率在数值上又应该是 0 至 1，所以原始判别器为了将输出归一化为 0 至 1，其最后一层通常会采用 Sigmoid 等激活函数。而在 WGAN 算法中，判别器的作用是对输入样本的真实性进行打分，因此不需要使用 Sigmoid 之类的激活函数进行归一化。

针对本研究中构建的判别模型和生成模型，在计算它们的损失度量时，分别依照公式 3-7 和公式 3-8：

$$L_D = -\mathbb{E}_{x \sim P_r} [D(x)] + \mathbb{E}_{u \sim P_u} [D(G(u))] \quad (3-7)$$

$$L_G = -\mathbb{E}_{u \sim P_u} [D(G(u))] \quad (3-8)$$

对于本研究中设计的生成对抗网络在训练时使用的优化器是 RMSprop 优化器。选择该优化器是因为在 WGAN 算法中，判别器需要满足 1-Lipschitz 约束^[36]即它的梯度范数应小于等于 1。为了满足这一约束，一般可以对判别器进行权重剪裁，从而确保在使用该类算法时能够顺利进行生成对抗性学习。但是在对判别器进行优化时，应该尽可能令判别器的参数不会剧烈变化以至于破坏 1-Lipschitz 约束，使用 RMSprop 优化器可以稳定地优化判别器参数以满足上述约束条件。训练时设置轮次总数是 1000、单批次样本数为 20、学习速率为 0.0001。

3.3.3 虚拟样本生成与数据集扩充

上述生成对抗网络在各目标域数据集上充分训练后，生成的虚拟图像样本的示例如图 3.4 所示。

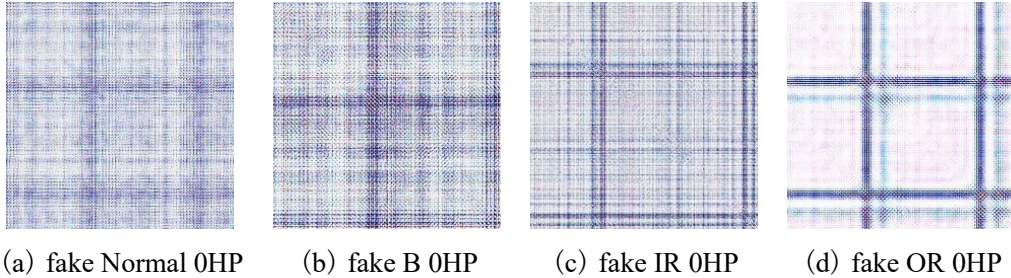


图 3.4 生成器生成虚拟 CWRU 样本示例图

以生成对抗网络学习行星齿轮箱数据集中源于 30Hz 工况下齿轮损坏设备状态信息的彩色图像样本的过程为例，设置的训练总轮次为 1000 轮，其中每隔 250 轮将生成的虚拟样本与真实样本进行 t-SNE 可视化的结果如图 3.5 所示。

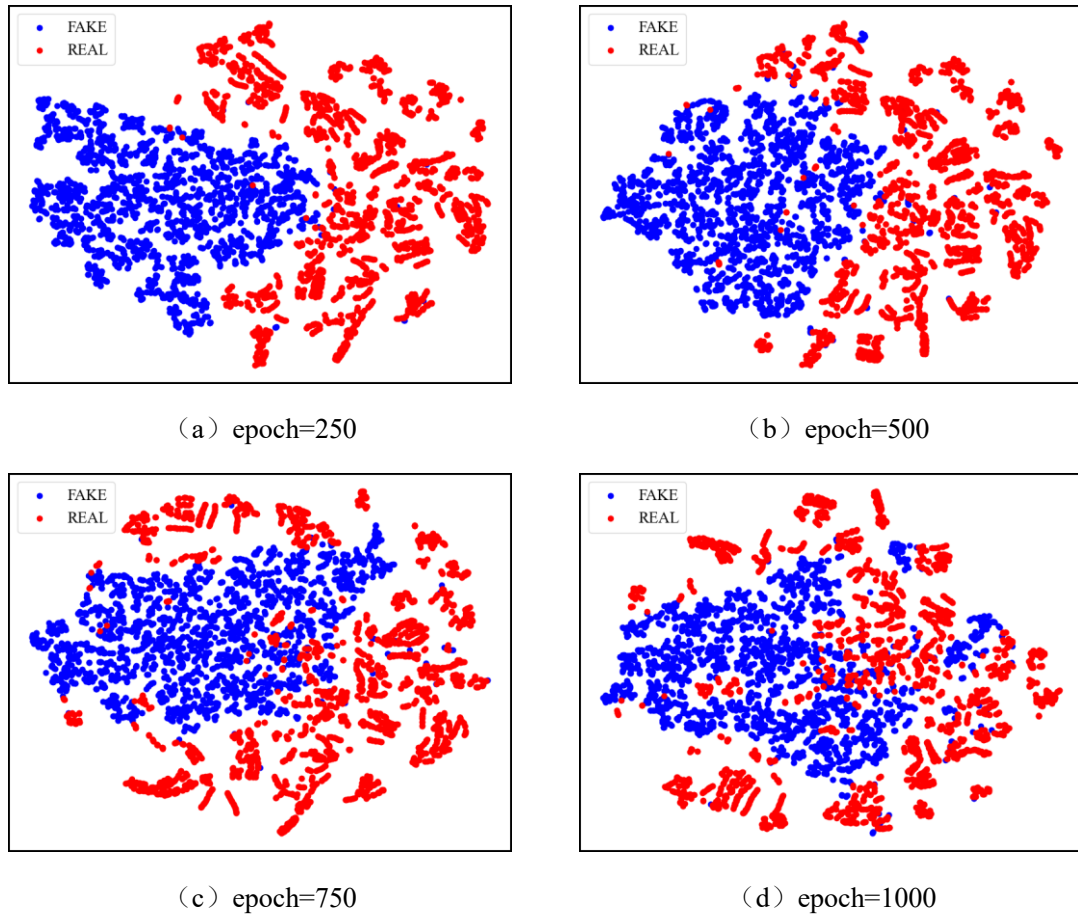


图 3.5 行星齿轮箱 30Hz 工况下训练过程中生成样本与真实样本的 t-SNE 分布演化图

通过对图 3.5 的观察可以发现，随着训练轮次的增加，代表两类样本的点在 t-SNE 可视化图中呈现融合趋势，当训练轮次为 1000 轮时，二者在 t-SNE 可视化图中融合趋势达到稳定。这一现象表明生成的虚拟样本的特征分布逐渐与真实样本接近，也就表明生成器已经学习到真实样本的特征分布，其生成的虚拟样本逼近于真实样本。

使用对抗性生成的结果增加各目标域中的数据后，将上述模拟数据集中的目标域部分替换为扩充后的数据集，从而获得跨域故障诊断数据集。

CWRU 跨域故障诊断数据集和行星齿轮箱跨域故障诊断数据集的结构分别如表 3.7 和表 3.8 所示。表中数值代表该域中样本个数、R 代表真实样本、F 代表虚拟样本。表中的各行是代表以某一工况为源域时跨域故障诊断数据集的结构，例如，在表 3.7 中第一行代表的情况是：以 0HP 工况为源域时，1HP、2HP、3HP 为目标域，源域下 7200 个样本均为来自 CWRU 完整数据集的真实样本，目标域的样本中有 4000 个是来自 CWRU 完整数据集的真实样本、有 3200 个是使用生成器生成的虚拟样本，因为任一目标域均有 4 种设备状态，所以任一目标域中代表某一设备状态的真实样本为 1000 个、虚拟样本为 800 个。

表 3.7 CWRU 跨域故障诊断数据集结构表

源域	所有域			
	0HP	1HP	2HP	3HP
0HP	7200R	4000R+3200F	4000R+3200F	4000R+3200F
1HP	4000R+3200F	7200R	4000R+3200F	4000R+3200F
2HP	4000R+3200F	4000R+3200F	7200R	4000R+3200F
3HP	4000R+3200F	4000R+3200F	4000R+3200F	7200R

表 3.8 行星齿轮箱跨域故障诊断数据集结构表

源域	所有域			
	20Hz	25Hz	30Hz	35Hz
20Hz	9600R	5600R+4000F	5600R+4000F	5600R+4000F
25Hz	5600R+4000F	9600R	5600R+4000F	5600R+4000F
30Hz	5600R+4000F	5600R+4000F	9600R	5600R+4000F
35Hz	5600R+4000F	5600R+4000F	5600R+4000F	9600R

3.4 本章小结

在本章中，从两类原始数据集中选择多个工况和设备状态的数据，对这些数据使用滑动窗口法进行截取，得到时间序列样本，并使用 GASF 算法和伪彩色增强技术将时间序列样本编码为彩色图像样本。使用源于两类原始数据集的全部彩色图像样本制作了两类完整数据集。为了模拟实际工业场景，本研究对两类完整数据集分为多种情况的源域数据集以及与其对应的目标域数据集，并删减目标域数据集中各设备状态下真实样本，从而制作了两类模拟数据集。之后使用基于 WGAN 算法的生成对抗网络在各删减后的目标域数据集上训练以生成虚拟样本，并用其扩充目标域数据集。多种跨域情况下的源域数据集及与其对应的扩充后目标域数据集合并，成为用于实现跨域诊断方法的数据集。

第四章 基于 CNN 和迁移学习的两阶段跨域诊断方法

4.1 引言

在上一章中，本研究已经实现使用滑动窗口法截取时间序列样本，以及使用 GASF 算法和伪彩色技术将时间序列样本编码为彩色图像，并用这些彩色图像制作可以模拟实际工业环境的数据集。此外，还设计并训练了生成对抗网络，用其扩充目标域数据集并制作用于跨域故障诊断的数据集。

通过以上实验构建的任一源域数据集和目标域数据集均可独立使用，由于卷积神经网络对图像类型数据具备较强的特征提取能力和模式识别能力，所以如果使用卷积神经网络仅在单一的源域数据集或目标域数据集上训练，则能够实现对该数据集所代表工况下的设备运行状态进行故障诊断。但是，以这种方式训练得到的卷积神经网络模型仅适用于简单地对单一工况进行故障诊断，若将其直接用于另一工况，则其在该工况下对设备状态的故障诊断准确率难以达到较高水平。为了能够在另一工况下也实现较高的故障诊断准确率，尽管也可以使用代表该工况的数据集从零开始重新训练一个适用于该工况的卷积神经网络模型，但是这种解决方法完全没有复用卷积神经网络在旧工况下学习到的、可以迁移到新工况的知识，此外如果为每种工况都单独重新训练卷积神经网络模型则会导致计算时间延长、训练成本增高的问题。

出现上述问题的原因在于，代表不同工况的数据集中数据的特征分布不同，所以针对某一数据集训练的卷积神经网络模型无法直接用于另一个数据集。针对该问题，本研究使用了一种基于微调技术和域适应技术与卷积神经网络相结合的两阶段跨域故障诊断方法（Two-Step Cross-Domain Fault Diagnosis Method, TS-CDFD）。

4.2 TS-CDFD 方法说明

4.2.1 方法流程说明

在本研究中所使用的该方法，对跨域故障诊断的实现需要分为两个阶段。

第一阶段为预训练阶段，即在所有常见工况或旧工况（源域）上分别训练 TS-CDFD 方法中的卷积神经网络并调整相关超参数，从而获得与源域对应的多个预训练模型参数。在该阶段完成后，方法中的卷积神经网络会具备在源域进行故障诊断的能力，但尚不能在目标域进行较准确的故障诊断。

此外，第一阶段还需统计预训练模型在各源域测试数据集上故障诊断的准确率，以验证该方法中所采用的卷积神经网络结构的有效性。

阶段一的训练流程即为普通的深度学习训练流程，所以不再赘述。阶段二的训练流程，即跨域故障诊断训练流程，如图 4.1 所示。

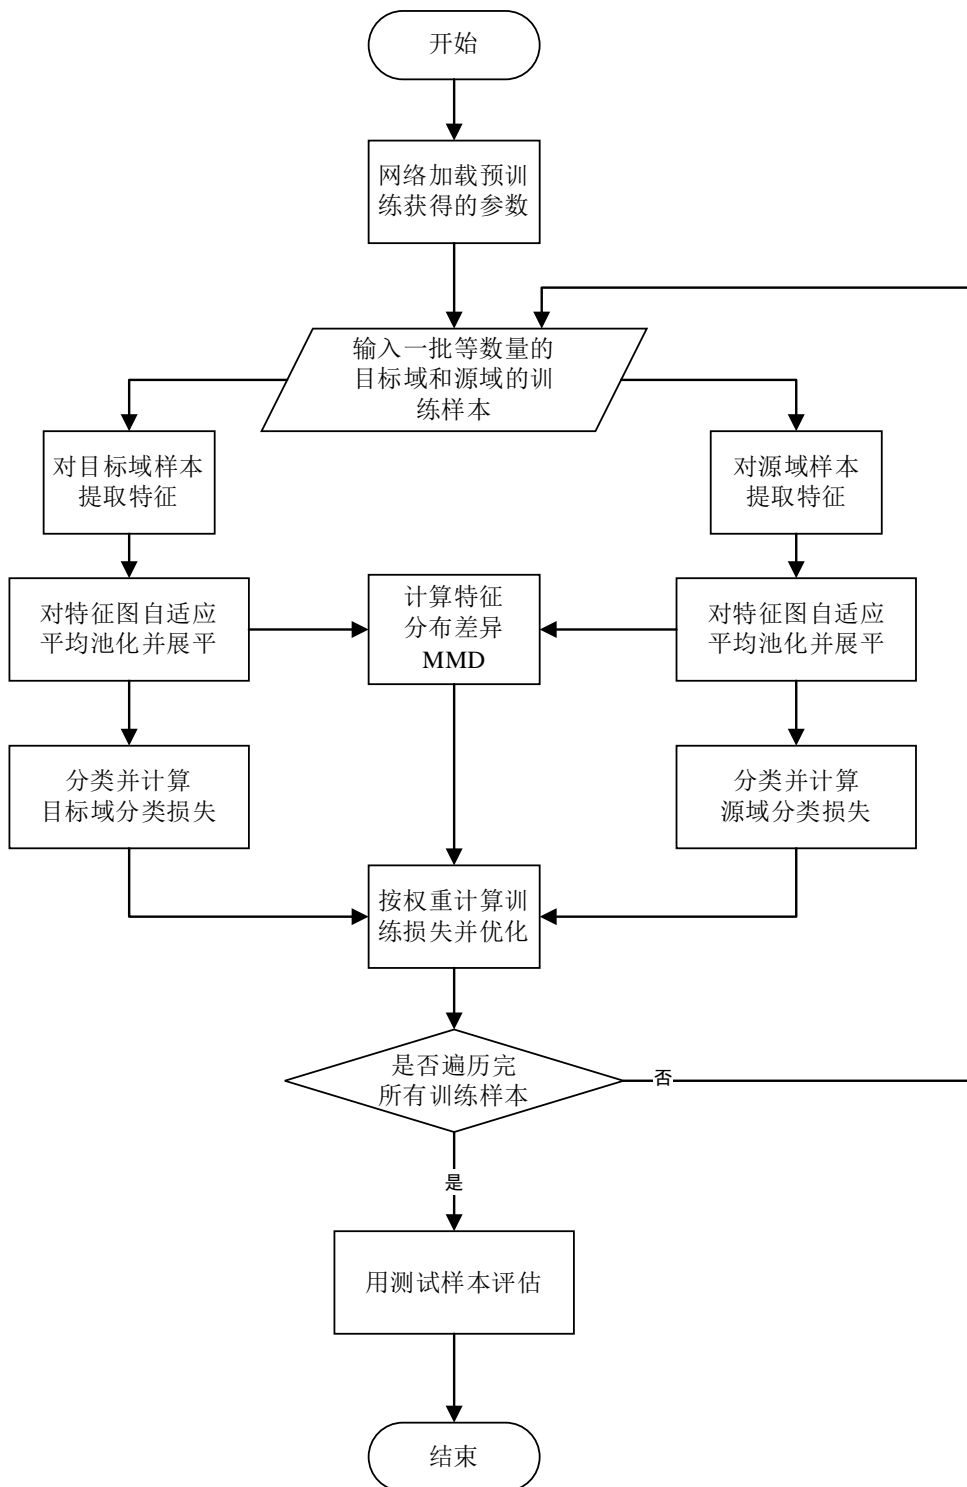


图 4.1 阶段二单轮跨域故障诊断训练流程示意图

第二阶段为跨域故障诊断的实现阶段，该阶段在进行训练流程时，首先使用由源域训练而得到的预训练模型参数作为初始权重，用来初始化方法中的卷积神经网络。在阶段二的训练过程中，不仅会使用来自目标域的数据对模型中的各个参数进行微调，还会依赖源域的数据作为输入，在训练时保留模型对源域样本的部分监督信息。同时还引入了由计算最大均值差异而实现的特征对齐机制，用于完成域适应策略，使得模型能更好地同时感知到两个域数据之间共同的属性。最终，第二阶

段的训练过程会综合利用上述三方面的信息，使得训练后得到的模型在具备对目标域故障诊断能力的同时，最大程度地保留对源域的故障诊断能力。

4.2.2 方法中网络结构说明

本研究所用方法的核心在于方法中的卷积神经网络，这一卷积神经网络的结构如表 4.1 所示。

表 4.1 卷积神经网络结构

层编号	层类型	核形状	步长	填充尺寸	输出通道数
1	Conv2d	11*11	4	2	96
2	ReLU	-	-	-	-
3	MaxPool2d	3*3	2	-	-
4	Conv2d	5*5	1	2	256
5	ReLU	-	-	-	-
6	MaxPool2d	3*3	2	-	-
7	Conv2d	3*3	1	1	384
8	ReLU	-	-	-	-
9	Conv2d	3*3	1	1	384
10	ReLU	-	-	-	-
11	Conv2d	3*3	1	1	256
12	ReLU	-	-	-	-
13	MaxPool2d	3*3	2	-	-
14	AdaptiveAvgPool2d((6, 6))	-	-	-	-
15	Flatten	-	-	-	-
16	Dropout(p=0.5)	-	-	-	-
17	Linear(9216, 4096)	-	-	-	-
18	ReLU	-	-	-	-
19	Dropout(p=0.5)	-	-	-	-
20	Linear(4096,4096)	-	-	-	-
21	ReLU	-	-	-	-
22	Linear(4096, 4)	-	-	-	-

在该网络的各层中，第 1 至 13 层用于提取输入的原始图像样本的特征。自适应平均池化层位于第 14 层，该层的功能是将之前各层对原始数据处理后输出的特征图池化为 (batch_size, 256, 6, 6) 的固定形状，从而使得该网络能适应不同形状的输入数据。第 15 层是将特征图展开成特征向量以输入后续各层。第 16 层至第 22 层通过对丢弃层、激活层、全连接层的组合使用，从而对特征向量进一步处理以实现判断输入样本所属的设备状态类型。

TS-CDFD 方法所使用的该卷积神经网络，其结构可以根据层的作用和层之间的关系，从而分为用于处理原始数据以获得特征向量的第一部分，以及对特征向量进一步处理以实现故障分类的第二部分。其中第 1 至 15 层是第一部分的构成层，输入第 1 层的是原始数据、从第 15 层输出的是可以表征原始数据的特征向量。第 16 至 22 层构成了第二部分，该部分将特征向量继续处理并进行分类从而实现对输入图像样本的故障分类。

4.2.3 各阶段中训练参数设置及损失值的计算方法

第一阶段训练时，仅使用到源域数据集。在该阶段训练以获得预训练模型参数的过程中，将完整的源域数据集中的数据，以 7:1:2 的比例划分为训练数据、验证数据和测试数据。第二阶段训练时需要并行地使用源域数据集和目标域数据集。在该阶段训练网络以实现跨域故障诊断的过程中，对目标域数据集中的数据仍按上述比例划分为训练数据、验证数据和测试数据，对于源域的训练数据、验证数据和测试数据的划分则与第一阶段保持一致。

在每个阶段的训练过程中，设置各轮训练中用于每一步训练的数据批次大小为 64，使用 SGD 优化器来更新网络的各层参数，训练时以 0.001 的速率进行学习。

由于第一阶段的训练过程中，输入的数据均来自源域，所以在该阶段训练损失的计算方法，是用交叉熵计算网络输出的对源域数据故障分类的结果与源域数据真实状态类别标签之间的误差值。此处计算得到的误差值，是训练时网络对输入数据故障分类出现错误所导致的分类损失。因此阶段一的训练损失计算方法如公式 4-1 所示：

$$\mathcal{L}_{\text{step1}} = \text{CrossEntropy}(C(F_s), Y_s) \quad (4-1)$$

公式中， F_s 是方法中网络的第一部分对源域数据感知到的特征向量； $C(F_s)$ 是网络处理源域数据后输出的故障类别标签； Y_s 是源域数据真实的故障类别标签； $\text{CrossEntropy}(C(F_s), Y_s)$ 是对输出的源域故障类别标签和源域数据真实故障类别标签以交叉熵计算得到的误差值； $\mathcal{L}_{\text{step1}}$ 表示第一阶段的训练损失。

第二阶段的训练过程中，网络需要并行地接收并处理来自源域和目标域的数据。与第一阶段类似，该过程中也需要计算由于分类错误而导致的误差值。但不同之处在于，还需要引导网络感知并对齐源域数据和目标域数据的相似属性，从而提升网络的跨域适应能力。因此，第二阶段训练损失的计算方法如公式 4-2 所示：

$$\begin{aligned} \mathcal{L}_{\text{step2}} = & \lambda \cdot \text{MMD}(F_s, F_t) + \gamma \cdot \text{CrossEntropy}(C(F_s), Y_s) + \\ & \beta \cdot \text{CrossEntropy}(C(F_t), Y_t) \end{aligned} \quad (4-2)$$

公式中， F_t 是方法中网络的第一部分对目标域数据感知到的特征向量； $C(F_t)$ 是网络处理目标域数据后输出的故障类别标签； Y_t 是目标域数据真实的故障类别标签； $\text{CrossEntropy}(C(F_t), Y_t)$ 是对输出的目标域故障类别标签和目标域数据真实故障类别标签以交叉熵计算得到的误差值； $\text{MMD}(F_s, F_t)$ 是计算源域数据特征向量和目

标域数据特征向量的最大均值差异； λ 、 γ 、 β 是三部分损失值在训练损失中的权重； $\mathcal{L}_{\text{step2}}$ 表示阶段二的训练损失。

4.3 实验设计

4.3.1 跨域诊断任务介绍

在具体运用 TS-CDFD 方法时，针对 CWRU 跨域诊断数据集和行星齿轮箱跨域诊断数据集，需要分别以各工况为源域、其他工况为目标域进行跨域故障诊断训练。由于本研究设计的这两类数据集中分别各有 4 类工况，且本研究针对的是从一个源域工况向另一个目标域工况进行的跨域，所以每一次跨域均需要完成一次跨域训练任务。因此，当选定任一工况为源域时均需完成 3 次跨域任务，即 3 次跨域故障诊断训练。

为了便于表述，本研究为每一个跨域故障诊断任务均设定了相应的代称，对于两个数据集中各个跨域故障诊断任务的代称，分别列于表 4.2 和表 4.3 中。

表 4.2 CWRU 跨域故障诊断任务代称表

源域	目标域			
	0HP	1HP	2HP	3HP
0HP	-	0T1	0T2	0T3
1HP	1T0	-	1T2	1T3
2HP	2T0	2T1	-	2T3
3HP	3T0	3T1	3T2	-

表 4.3 行星齿轮箱跨域故障诊断任务代称表

源域	目标域			
	20Hz	25Hz	30Hz	35Hz
20Hz	-	20T25	20T30	20T35
25Hz	25T20	-	25T30	25T35
30Hz	30T20	30T25	-	30T35
35Hz	35T20	35T25	35T30	-

如上所述，所有的跨域故障诊断任务均有其代称，对代称的解释，以表 4.2 中的“0T1”和表 4.3 中的“20T25”为例，代称“0T1”是指从 0HP 源域向 1HP 目标域的跨域故障诊断任务、代称“20T25”是指从 20Hz 源域向 25Hz 目标域的跨域故障诊断任务。CWRU 跨域故障诊断数据集和行星齿轮箱跨域故障诊断数据集中，各自分别有 12 个跨域故障诊断任务。

4.3.2 实验步骤设置

本研究将 TS-CDFD 方法用于 CWRU 跨域故障诊断数据集和行星齿轮箱跨域故障诊断数据集时,所做的相关实验,共分为三个步骤。

第一个步骤对应于方法的第一阶段。实行该步骤时,需要在各源域上分别训练方法中的卷积神经网络,以获得来自各个源域的预训练模型及其模型参数,训练时的参数设置和训练中损失值的计算方法参照 4.2.3 小节。同时,在该步骤中,要统计方法第一阶段获得的预训练模型在各源域测试数据集上故障诊断的准确率,从而验证该方法中所采用的卷积神经网络结构的有效性。该步骤中,在 CWRU 跨域故障诊断数据集中的源域数据上训练时,设置总训练轮次为 150 轮;在行星齿轮箱跨域故障诊断数据集中的源域数据上训练时,设置总训练轮次为 200 轮。

第二个步骤对应于方法的第二阶段。此时,需要按照方法第二阶段的训练流程,完成各个跨域故障诊断任务。对该步骤中跨域故障诊断任务的具体说明,以表 4.2 中 0HP 工况作源域时为例。此时,第一个目标域是 1HP,则第一个跨域故障诊断任务是从 0HP 工况向 1HP 工况的跨域,首先要将方法第一阶段在 0HP 源域上训练后获得的预训练模型参数加载进网络中,再以相同样本数向网络中输入一批源域样本以及目标域样本,此后,按照图 4.1 所示单轮次跨域故障诊断训练的流程训练若干轮,训练时的参数设置和训练中损失值的计算方法参照 4.2.3 小节。在完成从 0HP 工况向 1HP 工况的跨域故障诊断任务后,会继续完成 0HP 工况向 2HP 工况、向 3HP 工况的跨域故障诊断任务。当上述任务全部完成后,以 0HP 工况为源域的所有跨域故障诊断任务则已完成,继续以另一工况为源域完成对应的跨域故障诊断任务。在该步骤中,完成 CWRU 跨域故障诊断数据集中相关跨域故障诊断任务时,设置总训练轮次为 50 轮;完成行星齿轮箱跨域故障诊断数据集中相关跨域故障诊断任务时,设置总训练轮次为 60 轮

第三个步骤是设置对照实验,以验证第三章中增加源域样本数据这一操作的有效性。在该步骤中,选择行星齿轮箱跨域故障诊断任务中以 30Hz 工况为源域而进行的相关任务。具体而言,目标域工况分别是 20Hz、25Hz、35Hz 工况,仍然分别执行 30Hz 工况向上述目标工况的跨域故障诊断任务,并保持每个任务的总训练轮次仍然为 60 轮。但不同于第二个步骤的是,此时不对目标工况中的数据进行增加,而是保持目标工况中的数据少于源域工况数据。完成在该设置下相关跨域故障诊断任务并记录实验结果,将该结果与第二个步骤中采用增加目标域数据量操作时所得到的实验结果进行对比分析。

4.4 结果分析

4.4.1 源域训练结果分析

在完成第一个实验步骤后,可以得到由 CWRU 跨域故障诊断数据集和行星齿轮箱跨域故障诊断数据集中各个源域数据训练出的预训练模型,这些模型在其对应源域的测试数据上最终故障诊断的准确率记录在表 4.4 和表 4.5 中。训练过程中,模型在两个数据集的源域测试数据上故障诊断的准确率随着训练轮次增加而发生

的变化如图 4.2 和图 4.3 所示

表 4.4 各模型对源域测试集诊断准确率（CWRU 数据，Epoch=150）

源域测试集	准确率
0HP	97.29%
1HP	97.92%
2HP	99.44%
3HP	95.42%

表 4.5 各模型对源域测试集诊断准确率（行星齿轮箱数据，Epoch=200）

源域测试集	准确率
20Hz	93.39%
25Hz	88.33%
30Hz	95.26%
35Hz	96.98%




图 4.2 各模型在对应源域验证数据上诊断准确率随轮次变化图（CWRU 数据）





图 4.3 各模型在对应源域验证数据上诊断准确率随轮次变化图（行星齿轮箱数据）

表 4.4 和表 4.5 中的数据说明，本研究使用的卷积神经网络在单个前文所述制作的源域数据集上训练一定轮次后，可以具备对设备健康状态进行诊断的能力。但是，从图 4.2 可以观察到，如果 TS-CDFD 方法中的网络在没有参数可供初始化的条件下从零开始训练，在 CWRU 跨域故障诊断数据集的各个源域数据集上需要 150 轮左右的训练才能得到较好的故障诊断效果。而从图 4.3 可以观察到，因为根据行星齿轮箱数据制作的数据集相较于前者更加复杂、数据量更大，所以，在训练了 200 个轮次后，网络虽然具备了一定的故障诊断能力，但是训练后网络仍然没有收敛、故障分类效果仍然不稳定。


对实验步骤一结果的分析表明，TS-CDFD 方法中的网络在训练后可以对两类数据集中代表不同设备状态的数据进行分类，能够实现本研究所要求的故障诊断功能，证明了该网络结构的有效性。

4.4.2 跨域故障诊断任务结果分析


实验步骤二是完成各个跨域故障诊断任务所需的训练。在为了完成这些任务而进行的相关跨域故障诊断训练时，各模型在其对应的目标域验证数据上故障诊断的准确率随训练轮次的变化分别图 4.4 和图 4.5 所示。完成跨域故障诊断任务的训练后，各模型在其对应源域和目标域测试数据上故障诊断的准确率分别记录在表 4.6 和表 4.7 以及表 4.8 和表 4.9 中。




(a) 0HP 源域向目标域跨域诊断训练时准确率随轮次变化图



(b) 1HP 源域向目标域跨域诊断训练时准确率随轮次变化图




(c) 2HP 源域向目标域跨域诊断训练时准确率随轮次变化图

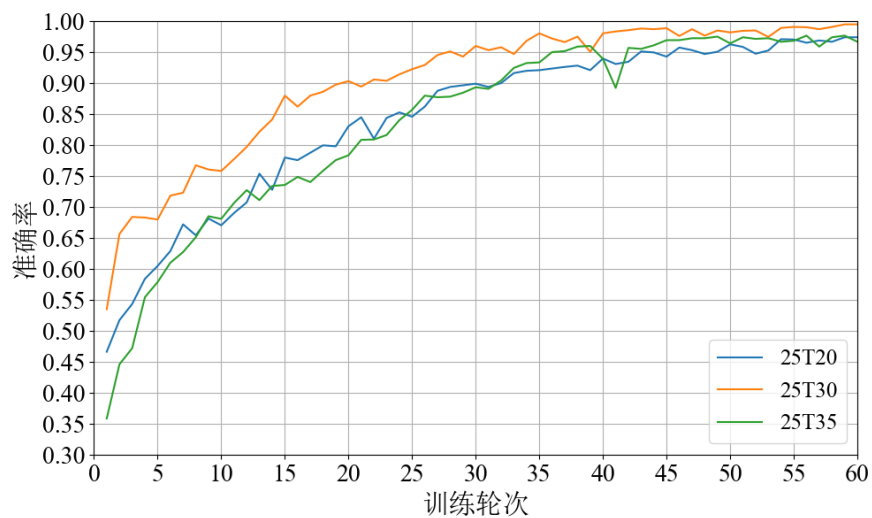


(d) 3HP 源域向目标域跨域诊断训练时准确率随轮次变化图

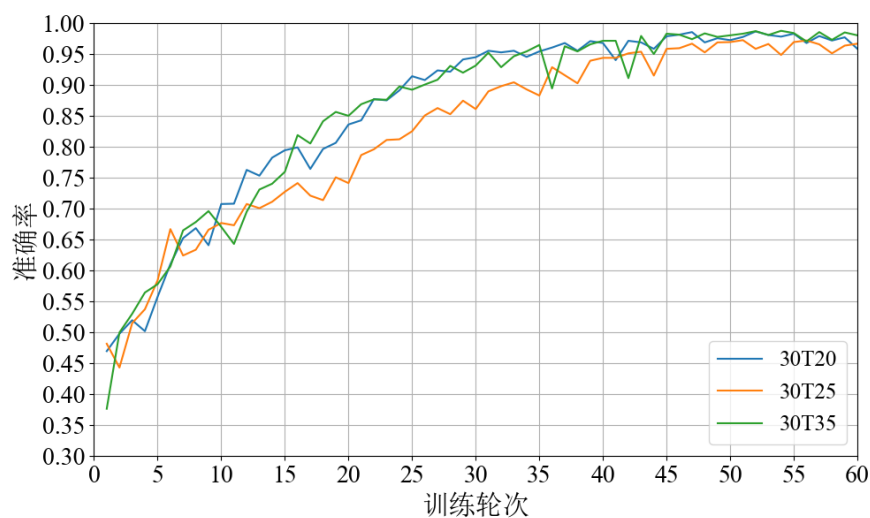
图 4.4 各模型对目标域验证数据诊断准确率随训练轮次变化图 (CWRU 数据)




(a) 20Hz 源域向目标域跨域诊断训练时准确率随轮次变化图



(b) 25Hz 源域向目标域跨域诊断训练时准确率随轮次变化图



(c) 30Hz 源域向目标域跨域诊断训练时准确率随轮次变化图



(d) 35Hz 源域向目标域跨域诊断训练时准确率随轮次变化图

图 4.5 各模型对目标域验证数据诊断准确率随训练轮次变化图（行星齿轮箱数据）

表 4.6 跨域诊断训练后模型对源域测试集诊断准确率（CWRU 数据）

源域	目标域			
	0HP	1HP	2HP	3HP
0HP	-	99.65%	99.31%	98.13%
1HP	99.58%	-	99.65%	98.96%
2HP	98.26%	99.86%	-	99.38%
3HP	96.32%	95.49%	96.39%	-

表 4.7 跨域诊断训练后模型对源域测试集诊断准确率（行星齿轮箱数据）

源域	目标域			
	20Hz	25Hz	30Hz	35Hz
20Hz	-	96.56%	97.08%	96.20%
25Hz	96.04%	-	96.15%	96.56%
30Hz	98.33%	98.54%	-	98.39%
35Hz	98.85%	98.85%	99.64%	-

表 4.8 跨域诊断训练后模型对目标域测试集诊断准确率（CWRU 数据）

源域	目标域			
	0HP	1HP	2HP	3HP
0HP	-	99.79%	99.86%	97.57%
1HP	94.17%	-	99.86%	97.43%
2HP	99.51%	99.79%	-	97.15%
3HP	99.31%	98.75%	98.54%	-

表 4.9 跨域诊断训练后模型对目标域测试集诊断准确率（行星齿轮箱数据）

源域	目标域			
	20Hz	25Hz	30Hz	35Hz
20Hz	-	96.72%	98.28%	96.35%
25Hz	96.93%	-	99.48%	97.55%
30Hz	99.11%	97.14%	-	98.65%
35Hz	97.34%	97.60%	98.59%	-

对图 4.4 和图 4.5 的分析表明，本研究使用的 TS-CDFD 方法，由于在第二阶段综合运用了微调技术和域适应技术，所以大幅减少了训练收敛所需的轮次，如在 CWRU 跨域诊断数据集上进行跨域故障诊断训练时仅需 50 轮的训练就可以在目标域测试数据上实现较好的故障诊断准确率，远少于第一阶段单纯在源域上预训练时所需的 150 轮；在行星齿轮箱跨域诊断数据集上进行跨域故障诊断训练时，虽然需要 60 轮的训练才能达到较稳定的故障诊断效果，但是使故障诊断准确率超过 90%所需的训练轮次，也仍然少于第一阶段单纯在源域上预训练时所需的轮次。除此之外，表 4.6 和表 4.7 以及表 4.8 和表 4.9 中的数据说明，训练后得到的跨域故障诊断模型，不仅可以在目标域较准确地进行故障诊断，而且，因为第二阶段训练时对源域分类损失的保留和对网络感知到的两个域样本的特征进行了对齐，所以该模型还可以保留其在对应源域故障诊断的能力。

4.4.3 对比实验结果分析

在实验步骤三中，以行星齿轮箱跨域故障诊断数据集里将 30Hz 工况作源域的任务为例，对增加目标域数据和不增加目标域数据这两种情况下跨域故障诊断任务的训练效果进行对比。

表 4.8 中记录了两种情况下，跨域故障诊断任务训练后最终各模型在对应目标域测试数据上故障诊断的准确率。图 4.6 所示，是两种情况下分别执行 30T35 跨域故障诊断任务的训练过程中，模型在目标域测试数据上故障诊断准确率随轮次变化的对比。

表 4.10 两种条件下训练后各模型对各目标域测试集故障诊断准确率

是否扩充	跨域任务		
	30T20	30T25	30T35
是	99.11%	97.14%	98.65%
否	91.87%	90.89%	93.66%




图 4.6 两种情况下模型对目标域验证数据诊断准确率随训练轮次变化对比图

表 4.10 和图 4.6 中的结果表明，当均使用较少的训练轮次时，在增加目标域数据的条件下完成跨域故障诊断任务后得到的模型，对目标域测试数据故障诊断的准确率要优于不增加目标域数据时的结果。而且，增加目标域数据的情况下，模型在训练过程中收敛速度更快。上述结果证明，适当增加目标域数据，有助于提升跨域故障诊断训练的效果。

4.5 本章小结

在本章中，说明了用于跨域故障诊断的卷积神经网络的相关信息，以及将卷积神经网络与微调技术和域适应技术结合后实现两阶段跨域故障诊断方法的相关过程。还对比分析了卷积神经网络在源域上预训练和跨域故障诊断训练时的训练效

果，证明了使用本研究所提的两阶段跨域故障诊断方法在跨域故障诊断训练时收敛更快，具有较高的效率。除此之外，还证明了完成跨域故障诊断训练后获得的模型，不仅具备在目标域故障诊断的能力，且保留了其在源域故障诊断的能力。同时也验证了在本研究中，增加目标域数据量有助于提升跨域故障诊断训练的效果。

第五章 总结与展望

5.1 研究总结

本研究聚焦于基于跨域适应的风电传动链智能故障诊断方法。此节是对研究内容的简要总结。

首先，阐明了研究基于跨域适应的风电传动链智能故障诊断方法是有需求且有意义的：风力发电在可再生能源发电中占有重要地位，而风电机组的传动链故障是导致风电机组非计划停机的主要因素而且会造成严重经济损失，因此研究更智能的风电传动链故障诊断方法具有重要意义。

本研究对轴承故障数据集和行星齿轮箱数据集使用滑动窗口法、格拉姆角和场算法等方法制作了模拟实际工业场景的数据集。并且搭建了基于 WGAN 算法的生成对抗网络实现了对目标域数据集的扩充从而制作了跨域故障诊断数据集。

本研究还实现了将卷积神经网络与微调技术和域适应技术相结合的两阶段跨域诊断方法，并使用该方法在两类跨域故障诊断数据集上进行验证，以证明该方法具有较好的跨域故障诊断效果

5.2 研究展望

本研究针对的目标域是有标签的数据集，这就要求小概率工况或新工况下的少量样本均已经标注了其所属的设备状态。然而，在实际工业环境中无法保证每一个目标域数据集均已完成标注。因此，未来的研究仍需要进一步探索弱监督甚至无监督的跨域故障诊断方法。除此之外，本研究使用的是离线学习的方法，即数据处理、模型训练和模型评估的过程中，所依赖的数据均是提前采集和整理好的数据，而不是实时数据。但是，在实际工业环境中风电机组的设备状态信息是不断产生的。因此，如何使用在线学习的方式继续探索更有实际应用价值的跨域故障诊断方法也是未来的重要研究方向。

结束语

本研究对风电传动链小概率工况或新工况下（目标域）的故障诊断准确率受限于设备状态信息不足的问题，实现了一套运用生成对抗网络和迁移学习技术的解决方案。本研究先使用 GASF 算法和伪彩色增强技术将时间序列类型的设备状态信息编码为彩色图像，又使用基于 WGAN 的生成对抗网络实现了对目标域数据集的扩充。研究中实现的将卷积神经网络与微调技术和域适应技术相结合的方法，可以使得网络只需较少的训练轮次，就能在目标域达到较高的故障诊断准确率，此外，还可以保持其在源域故障诊断的能力。

参考文献

- [1] 俞颖. 全球电力发展现状[J]. 电力科技与环保, 2025, 41(1): 173.
- [2] 中国可再生能源学会风能专业委员会. 2012年全国风电设备运行质量调查概述[J]. 风能, 2013, 4(9): 36-44.
- [3] 曾祥军. 数据驱动的风电机组齿轮箱异常检测与故障诊断研究[D]. 山东: 山东大学, 2022.
- [4] Sun H, Cao X, Wang C, et al. An interpretable anti-noise network for rolling bearing fault diagnosis based on FSWT[J]. Measurement, 2022, 190: 110698.
- [5] Zhang H, Chen X, Du Z, et al. Kurtosis based weighted sparse model with convex optimization technique for bearing fault diagnosis[J]. Mechanical Systems and Signal Processing, 2016, 80: 349-376.
- [6] 辛治铨, 汪隆君, 刘沈全. 基于迁移学习的海上风电机组轴承早期故障预警策略[J]. 可再生能源, 2024, 42(7): 915-922.
- [7] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [8] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.
- [9] 季长清, 高志勇, 秦静, 等. 基于卷积神经网络的图像分类算法综述[J]. 计算机应用, 2022, 42(4): 1044-1049.
- [10] 张珂, 冯晓晗, 郭玉荣, 等. 图像分类的深度卷积神经网络模型综述[J]. 中国图象图形学报, 2021, 26(10): 2305-2325.
- [11] 卢宏涛, 张秦川. 深度卷积神经网络在计算机视觉中的应用研究综述[J]. 数据采集与处理, 2016, 31(1): 1-17.
- [12] 李州, 汪繁荣. 基于CNN-SVM的变压器故障诊断方法[J]. 现代电子技术, 2025, 48(6): 73-77.
- [13] Huang D, Zhang W A, Guo F, et al. Wavelet packet decomposition-based multiscale CNN for fault diagnosis of wind turbine gearbox[J]. IEEE Transactions on Cybernetics, 2021, 53(1): 443-453.
- [14] 梁杰文. 基于迁移学习和EfficientNetV2的遥感图像场景分类[J]. 北京测绘, 2024, 38(11): 1521-1525.
- [15] Zhu JY, Park T, Isola P, Efros AA. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//ICCV. Proceedings of the IEEE International Conference on Computer Vision 2017. Venice: IEEE, 2017: 2223-2232.
- [16] 陈祝云. 基于深度迁移学习的机械设备智能诊断方法研究[D]. 广州: 华南理工大学, 2020.
- [17] Zhang S, Lei S U, Jiefei G U, et al. Rotating machinery fault detection and diagnosis based on deep domain adaptation: A survey[J]. Chinese Journal of Aeronautics, 2023, 36(1): 45-74.
- [18] Borgwardt KM, Gretton A, Rasch MJ, et al. Integrating structured biological data by Kernel

-
- Maximum Mean Discrepancy[J]. *Bioinformatics*, 2006, 22(14): 49-57.
- [19] Li X, Hu Y, Zheng J, et al. Central moment discrepancy based domain adaptation for intelligent bearing fault diagnosis[J]. *Neurocomputing*, 2021, 429: 12-24.
- [20] Li X, Zhang W, Ding Q. Cross-domain fault diagnosis of rolling element bearings using deep generative neural networks[J]. *IEEE Transactions on Industrial Electronics*, 2018, 66(7): 5525-5534.
- [21] Cheng C, Zhou B, Ma G, et al. Wasserstein distance based deep adversarial transfer learning for intelligent fault diagnosis with unlabeled or insufficient labeled data[J]. *Neurocomputing*, 2020, 409: 35-45.
- [22] Wang Z, Wang J, Wang Y. An intelligent diagnosis scheme based on generative adversarial learning deep neural networks and its application to planetary gearbox fault pattern recognition[J]. *Neurocomputing*, 2018, 310: 213-222.
- [23] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. *Nature*, 1986, 323(6088): 533-536.
- [24] IOFFE S, SZEGEDY C. Batch normalization: accelerating deep network training by reducing internal covariate shift[C]//ICML. *Proceedings of the 2015 International Conference on Machine Learning*. New York: JMLR, 2015: 448-456.
- [25] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative Adversarial Nets[C]//Z. Ghahramani, M. Welling, C. Cortes, N. D. Lawrence, K. Q. Weinberger. *Advances in Neural Information Processing Systems 27*. Montreal, Canada: Curran Associates Inc, 2014: 2672-2680.
- [26] 谢天圻, 吴媛媛, 敬超, 等. GAN模型生成图像检测方法综述[J]. *计算机工程与应用*, 2024, 60(22): 74-86.
- [27] 朱晓慧, 钱丽萍, 傅伟. 图像数据增强技术研究综述[J]. *软件导刊*, 2021, 20(5): 230-236.
- [28] 李嘉宁, 李喆, 陈海威, 等. 基于数据增强的变压器机械故障声纹识别方法[J]. *电气自动化*, 2024, 46(6): 106-108.
- [29] 聂磊, 杨浩明, 尹业寒, 等. 基于生成对抗网络数据增强的舰炮可靠性分析[J]. *火力与指挥控制*, 2024, 49(4): 38-43+50.
- [30] 程剑, 徐冰心, 刘宏哲, 等. 基于生成模型的计算机视觉数据增强方法综述[C]//中国计算机用户协会网络应用分会. *中国计算机用户协会网络应用分会2024年第二十八届网络新技术与应用年会论文集*. 北京: 北京联合大学北京市信息工程重点实验室; 北京联合大学机器人学院脑与认知智能北京实验室, 2024: 276-279.
- [31] Case western reserve university (CWRU) bearing data center[EB/OL]. [2025-04-10]. <https://csegroups.case.edu/bearingdatacenter/pages/download-data-file/>.
- [32] Liu D, Cui L, Cheng W. Fault diagnosis of wind turbines under nonstationary conditions based on a novel tacho-less generalized demodulation[J]. *Renewable Energy*, 2023, 206: 645-657.
- [33] Liu D, Cui L, Cheng W. A review on deep learning in planetary gearbox health state recognition: methods, applications, and dataset publication[J]. *Measurement Science and Technology*, 2023,

- [34] Perea, Jose A., Harer, John. Sliding windows and persistence: An application of topological methods to signal analysis[J]. Foundations of computational mathematics, 2015, 15(4): 799-838.
- [35] Wang Z, Oates T. Encoding time series as images for visual inspection and classification using tiled convolutional neural networks[C]//AAAI Conference Committee. Proceedings of the Workshops at the Twenty-Ninth AAAI Conference on Artificial Intelligence. USA: AAAI Press, 2015: 1-7.
- [36] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]//ICML. International conference on machine learning. Sydney: PMLR, 2017: 214-223.